

Modelos de Redes Neuronales para la teoría de Sistemas de Recuperación de Información

Andy González Peña, Juan Eray Álvarez Hernández

MATCOM, Universidad de la Habana

Abstract. El presente trabajo consta de apuntes literarios con lo cual se pretende resumir temas relacionados con Redes Neuronales dentro de los Modelos de Recuperación de Información dando así una base inicial para su entendimiento y sus aplicaciones de manera general. Comenzando con un poco de historia, se relatan los sucesos que conllevaron a las Redes Neuronales tal y como la conocemos en la actualidad, mientras el volumen de información a nivel global llega a condiciones abrumadoras toma gran importancia las temáticas de recuperación de información. Es, por tanto, que conociendo las condiciones del terreno, se llega a los aspectos claves que definen a una red neuronal y las razones por la que se considera un paradigma propio dentro de la teoría de estos sistemas. De manera culminante, se enumeran y ejemplifican algunas de sus aplicaciones dentro de la amplia gama que posee para las diferentes ramas del conocimiento.

deriva directamente de los modelos clásicos vectoriales ya que consisten de las mismas bases matemáticas, o sea, operaciones definidas en el Álgebra Lineal de vectores sobre un espacio t -dimensional; es decir, es la misma filosofía matemática para el cómputo de la respuesta óptima requerida por sus usuarios.

Aunque estos modelos no presumen de modelar el pensamiento humano en su totalidad, si proponen acercar la solución a disímiles problemas de la forma en la que nuestro cerebro lo haría, y así comienza la analogía ya no solo de nombre sino de accionar, tarea que se intenta entender en numerosas ramas de las ciencias y no de manera diferente que llega a las Ciencias de la Computación. Entonces, como todo sistema, este se compone de funciones de entrada y de salida y, como el antes mencionado modelo vectorial clásico, los vectores de entrada se podrán ver como nodos los cuales estarán conectados entre sí por una serie de aristas hasta llegar a los nodos de salida, de esta forma se implica la teoría de grafos dirigidos y ponderados aplicados en la teoría propia que se compone sobre las Redes Neuronales.

1 Introducción

La recuperación de información puede tomar muchas formas, desde una consulta de texto, ya sea escrita o interpretada por un software de reconocimiento de voz, o una imagen o video, entre muchas otras. El proceso incorpora la evaluación de sus resultados según su relevancia optando por brindar una respuesta de mayor calidad para sus usuarios. Dicho esto, se puede definir que, desde su núcleo, una red neuronal es un modelo alternativo algebraico dentro de la teoría de estos sistemas el cual se

Sin llegar a profundizar mucho más por el momento comencemos enumerando los principales eventos y formulaciones que conformaron toda la teoría que conocemos en la actualidad permitiéndonos extender y plantear los fundamentos teóricos presentes y así llegar al entendimiento básico o general de uno de los temas que más auge va tomando en los últimos años debido al gran número de aplicaciones que tiene para muchas subramas de las Ciencias de la Computación como son *Machine Learning* o Procesamiento de Lenguaje Natural (PLN), entre muchas otras.

2 Historia

Las redes neuronales se basan en un modelo computacional el cual fue biológicamente inspirado: exactamente como su nombre indica, pretende simular el procesamiento de información, como por ejemplo, dar solución a un problema específico o construir su propio conocimiento tal y como un humano lo haría.

Los estudios neurobiológicos distinguen al menos tres niveles siguiendo la línea de procesar información: estructural, fisiológico y cognitivo. En el nivel estructural se puede observar las neuronas, sus regiones y los puentes que las conectan, mientras en el nivel fisiológico se define la forma en que tales conexiones serán realizadas y, de manera culminante, en el nivel cognitivo es donde se decide cuales de esas conexiones devuelven la información necesaria para responder a una situación específica.

El funcionamiento del cerebro humano es impresionante y siempre ha sido el deseo de numerosos campos científicos desarrollar avances que parezcan o repliquen tal comportamiento, y es así como en las Ciencias de la Computación se inserta en el mismo afán cuando en 1943 [2] Warren McCulloch y Walter Pitts crearon el primer modelo computacional de redes neuronales llamada frontera lógica, estableciendo las bases matemáticas de los tres niveles de procesamiento de información en el cerebro donde las neuronas serían nodos de un grafo y la sinapsis de sus conexiones serían las aristas de su densidad, mientras que el nivel cognitivo quedaría resumido en el algoritmo de su modelo.

Con este primer modelo quedaron bien marcadas las dos ramas fundamentales para su aplicación: enfocada en los procesos biológicos del cerebro y su aplicación en inteligencia artificial.

2.1 Aprendizaje de Hebb

A fines de la década de 1940 el psicólogo y padre de la rama denominada biopsicología Donald

Hebb creó una hipótesis de aprendizaje basado en el mecanismo de plasticidad neuronal. A pesar, de parecer un desvío de tópico es importante ver como existe la retroalimentación dentro de los mecanismos computacionales posteriormente inspirados sobre él.

Consideremos tres neuronas A, C y B de un perro. La neurona A recibe sonido desde una campanilla, la neurona C recibe la imagen de la comida ofrecida al perro, mientras que la neurona B, al quedar excitada, activa el proceso de salivación en el perro.

Entrada de sonido $\rightarrow A \rightarrow B \rightarrow$ Salivación

Entrada visual $\rightarrow C \rightarrow /$

Supongamos que la excitación de C, causada por la visualización de la comida, es suficiente para excitar a B, dando lugar a la salivación.

Supongamos, además, que en ausencia de estímulo adicional, la excitación de A, al oír la campanilla, no basta para dar lugar al disparo de B.

Permitamos que C de lugar a que B dispare mostrando comida al sujeto y, mientras B sigue disparando, estimulemos A haciendo sonar una campanilla. Dado que B sigue disparando, A participa ahora en la excitación de B, aún cuando por sí sola A no sería suficiente para dar lugar a que B dispare.

En esta situación, la suposición de Hebb determina que se produce algún cambio entre A y B, de tal modo que la influencia de A sobre B se ve incrementada. Si el experimento se repite con suficiente frecuencia, A será capaz de lograr, eventualmente, que se dispare B incluso en ausencia de la estimulación visual procedente de C. Entonces, si se hace sonar la campanilla, pero no se muestra la comida, seguirá produciéndose la salivación, porque la excitación debida únicamente a A es ahora suficiente para lograr que B dispare.

Dado que la conexión entre neuronas se hace a través de la sinapsis, es razonable suponer que cualquier cambio que pueda tener lugar durante el aprendizaje deberá producirse en ellas. Hebb sostenía la teoría de que aumentaba el área de la unión sináptica.

Luego, siguiendo la analogía neurona-nodos desde 1948 comenzó su aplicación para modelos computacionales en máquinas de Turing tipo-B. MIT no estuvo tan lejos, Farley y Wesley Clarke simularon una red Hebbian en 1954, mientras en 1956 otras redes neuronales fueron creadas por Rochester, Holland, Habit y Duda.

Aunque el verdadero ejemplo de aprendizaje y el modelo base de los actuales fue lanzado en 1958 por Frank Rosenblatt quien le llamó *perceptron*, utilizando un algoritmo de reconocimiento de patrones basado en una red de aprendizaje de dos capas usando simplemente sumas y restas, cambiando la idea de procesamiento que adquieren las redes neuronales.

2.2 Perceptron




Fig 1. *Perceptron*

Entre los primeros modelos aplicables de redes neuronales tenemos el *perceptron*, el cual, en su visión simplista, definía que la función de activación neuronal, o actividad sináptica, era una función lineal donde su entrada, de manera general, serían números reales y las salidas se daban en binario. En la figura 1 se muestra la analogía de las tres neuronas del ejemplo de Hebb (y un *bias*).

Por definición está compuesto por dos capas de neuronas, una para la entrada y otra para la salida y se asumen completamente conectadas

entre sí, mientras que los costos o pesos de las conexiones para la entrada ya están previamente fijados y luego a través de su algoritmo interno de aprendizaje calcula los pesos para su salida.




Fig 2. *Clases Lineales*

Un ejemplo de uso de *perceptron* es el de reconocer puntos en el plano bidimensional (x_1, x_2) donde existen dos posibles clases de soluciones, las cuales son linealmente separables y, por ende, luego de número finito de corridas a través del perceptron, este asegura su convergencia.

Sin embargo, exactamente ese fue uno de los problemas encontrados por Minsky y Papert en 1969, cuando lanzan un artículo demostrando las limitantes del perceptron. Si las clases de solución no eran linealmente separables entonces el modelo jamás convergerá.

2.3 Backpropagation

En consecuencia, para resolver la limitación de separabilidad lineal, surge el *perceptron* multicapas (MLP) el cual es, en principio, lo mismo que su propuesta anterior con la diferencia de que entre las capas de entrada y salida existen n -capas tal que juntas toman el nombre de capas ocultas.

Además, se pretende que las conexiones intermedias tengan el mayor número de conexiones posibles con el objetivo final de optimizar la respuesta, aunque en la práctica no siempre se pueda tomar de esa forma.




Fig 3. MLP

Sin embargo, este modelo no sería capaz de reutilizar el algoritmo original para el aprendizaje de un *perceptron*, al menos no hasta que en 1975 se lanza el algoritmo de *backpropagation*.

Para su aplicación, las neuronas del MLP se consideran en un estado constante de entradas y salidas, con una función no lineal de activación. Mientras se asume un error E para un ciclo determinado, se puede aplicar la regla del gradiente descendiente para encontrar la conexión óptima entre los pesos $w_{i,j}$ con lo cual se asegura que luego de número finito de ciclos el error E será suficientemente pequeño.

Entonces, para un ciclo $t+1$ la variación del peso de un nodo $\Delta w_{i,j}$ se calcula de la siguiente manera:

$$\Delta w_{i,j}(t+1) = \text{rate} * \text{Err}_j * o_j * (1 - o_j) * o_i$$

Donde Err_j es el error entre el valor deseado en la salida y_j y el valor o_j producido por la neurona j , lo cual puede ser expresado como $\text{Err}_j = |y_j - o_j|$.

En cada ciclo (iteración, época) el algoritmo consta de dos fases:

1. Hacia adelante es cuando las entradas pasan a propagarse hasta llegar a las neuronas de salida y computar un respuesta.
2. Hacia atrás es cuando el error es calculado y no cumple con los requisitos de mínimo,

entonces se propaga hacia los nodos intermedios provocando los cambios de peso $\Delta w_{i,j}$.

Mientras el error se propaga de vuelta, el Err_i para un nodo i intermedio es calculado multiplicando todos los errores Err_j de todas las neuronas j adyacentes a la neurona i mediante su peso correspondiente $w_{i,j}$. El procedimiento se repite hasta que el error global sea suficientemente pequeño.

3 Modelo

En todo sistema de recuperación de información derivado de los modelos algebraicos clásicos, los vectores de documentos son comparados con los vectores de consulta para calcular su relevancia y por ende los términos de índices en documentos y consultas deberán ser comparados y pesados para computar tal relevancia.




Fig 4. Modelo MLP para la RI

Una red neuronal es una representación simplificada del cerebro humano utilizando grafos, donde los nodos se comportan como neuronas y las aristas como las conexiones sinápticas. En cada instante, un nodo es definido por su nivel de activación (función de su estado inicial y las señales que recibe como parámetro). Entonces, dependiendo de su nivel de activación, un nodo A podría emitir una señal a otro nodo adyacente B . La fuerza de la señal en el nodo B depende directamente del peso asociado a la arista que une los nodos A y B .

En el proceso de hacia atrás descrito anteriormente, tales señales tienen relación directa con el error y por ende, mientras pasan épocas de ejecución tales señales se debilitan.

Para los nodos de consulta son asignados un valor de activación inicial de 1 (máximo), con los cuales pasan a la siguiente capa de nodos de la red neuronal y envían su señal de activación a los nodos correspondientes atenuadas según la normalización de los pesos de sus aristas $\bar{w}_{i,q}$.

$$\bar{w}_{i,q} = \frac{w_{i,q}}{\sqrt{\sum_{i < t} w_{i,q}^2}}$$

De la misma forma se calcularán los pesos para cada arista entre sus nodos correspondientes de las distintas capas de la red neuronal en cuestión. Finalmente, cuando la señal llega a un nodo documento d_j su nivel de activación está dado por:

$$\sum_{i < t} \bar{w}_{i,q} \bar{w}_{i,j} = \frac{\sum_{i < t} w_{i,q} w_{i,j}}{\sqrt{\sum_{i < t} w_{i,q}^2} \sqrt{\sum_{i < t} w_{i,j}^2}}$$

El cual coincide exactamente con la fórmula de relevancia del modelo clásico vectorial para la primera iteración de la red neuronal.

3.1 Definición Formal

Una red neuronal es un cuádruplo $RN = \langle Q, D, F, R \rangle$ donde:

Q—Conjunto de nodos de consulta donde todos tienen nivel de activación máxima y los pesos de las aristas correspondientes son las componentes del vector asociado a la consulta.

D—Conjunto de nodos de documentos con funciones de entrada y salida de señales en la cual los pesos de las aristas que les inciden son las componentes del vector asociado a la salida de la red neuronal.

F—Como derivado del modelo vectorial se enmarca en la teoría del Álgebra Lineal de vectores y sus operaciones sobre un espacio t -dimensional y, además, involucra la teoría de grafos, estos dirigidos y ponderados como

parte de la propia teoría de redes neuronales.

R—Función de relevancia (ranking) enunciada anteriormente y la misma que en el modelo vectorial.

Como definición conjunta se puede definir como una función $F : \bar{x} \rightarrow R, F(x, \Theta)$ tal que Θ contiene los parámetros que permiten realizar un mapeo del objeto de entrada x y se devuelve otro objeto y .

3.2 Comparación

A continuación se presentan los principales aspectos que definen un sistema de recuperación puestos en comparación con el modelo de Redes Neuronales.

Framework Booleano - Teoría de Conjuntos y Álgebra Booleana
 Vectorial - Espacio t -dimensional y Álgebra Lineal
 Redes Neuronales - Teoría de Grafos, Espacio t -dimensional y Álgebra Lineal

Pesos Booleano - $\{0, 1\}$
 Vectorial - $w_{i,j}$
 Redes Neuronales - $\bar{w}_{i,j}$

Consultas Booleano - Expresiones Booleanas
 Vectorial - Vectores de peso
 Redes Neuronales - Nodos

Documentos Booleano - Vectores Binarios
 Vectorial - Vectores de peso
 Redes Neuronales - Nodos

Similitud Booleano - $\{0,1\}$
 Vectorial - $\cos \alpha$
 Redes Neuronales - $\cos \alpha$

Dependencia Booleano - No
 Vectorial - No
 Redes Neuronales - Si

Correspondencia Parcial Booleano - No
 Vectorial - Si
 Redes Neuronales - Si

Ranking Booleano - No
 Vectorial - Si
 Redes Neuronales - Si

4 Ejemplo

Para entender el funcionamiento de las redes neuronales, se presenta a continuación un ejemplo ilustrativo de un red neuronal dedicada al reconocimiento de vocales a partir de una imagen.




Fig 5. Ejemplo. Reconocimiento en una imagen

Primeramente, el sistema debe conocer las muestras de cada vocal parametrizadas:

A: 01110100011000111111100011000110001

E: 11111100001000011100100001000011111

I: 11111001000010000100001000010011111

O: 01110100011000110001100011000101110

U: 10001100011000110001100011000101110

Fijar como número de entradas de la red 35, puesto que son 35 los números de la matriz resultante de 7×5 resultante de la

parametrización y como número de salidas 5 ya que esa es la cantidad de vocales.

Note que en una primera instancia no es necesaria una capa oculta, de manera empírica se pueden ir añadiendo capas con el objetivo de optimizar resultados o simplemente disminuir el tiempo en ejecución antes de dar tales resultados. Además, se puede evitar el uso de neuronas auxiliares (bias) y se utiliza como función de activación la sigmoideal (aunque pueden ser muchas otras).

Se fijan los valores iniciales de $lrate$, M , E_{min} como marco de trabajo donde:

- $lrate$ puede tomar valores entre 0 y 1. Usualmente se les da un valor medio.

- M puede tomar valores entre 0 y 1. Se utiliza para asegurar que el algoritmo no se caiga en ciclos en ninguno de los pasos

- E_{min} se define como cota de ejecución y es usualmente un valor lo suficientemente pequeño tal que el resultado se considere una respuesta aceptable.

5 Conclusiones

El alza de nuevas de tareas de recuperación de información demanda replantear muchas de las métricas que consideramos correctas para evaluar la relevancia de un documento en un sistema dada una consulta y, a la vez, para otra situación ser totalmente lo contrario. Es, por ende, que los modelos de Redes Neuronales deberán no solo evolucionar desde el punto de vista computacional, es decir, en cuanto a temas de optimización, sino que debe ser acompañado de numerosos aspectos que interactúan sobre ellos.

Está reflejado que a lo largo del tiempo, estos modelos han demostrado cuantiosos resultados para muchas ramas de la ciencia, con lo cual su importancia existe más allá del plano teórico, estando presentes en casi cada acción tecnológica que cada persona promedio realiza al menos una o dos veces al día y aún se encuentra en constante evolución.

References

1. Baeza-Yates, R., Ribeiro-Neto, B.: Modern Information Retrieval. Addison-Wesley, 1999 Longman Publishing Co., Inc., Boston, MA, USA
2. Kasabov, Nikola.: Foundations of Neural Networks, Fuzzy Systems and Knowledge Engineering. MIT Press, 2002, Cambridge, MA, USA
3. Wilkinson, R., Hingston, P.: Using the cosine measure in a neural network for document retrieval. 1991. In Proc of the ACM SIGIR Conference on Research and Development. Chicago, USA.
4. Mitra, B., Craswell, N.: An Introduction to Neural Information Retrieval. 2018. Foundations and Trends in Information Retrieval, Cambridge, UK.
5. Kenter, T., Borisov, A., Van Gysel, C., Dehghani, M., de Rijke, M., Azarbondy, H.: Lectures on Neural Networks for Information Retrieval. WSDN2018, University of Amsterdam, Netherlands.
6. Valle Vidal, C.: Lectures on Artificial Neural Networks. 2009. Universidad Técnica Federico Santa María, Santiago, Chile
7. Lopez, D., Navas, G.: Diseño y Construcción de una red neuronal de propósito general. 2007, Universidad Técnica Salesiana, Quito, Ecuador.